

Разработка и интерпретация моделей машинного обучения для прогнозирования рецидива диабетического кетоацидоза

Садыхов О.Б.¹, Леоненко В.Н.¹

¹ Университет ИТМО, факультет технологий искусственного интеллекта,

Санкт-Петербург, Россия

Автор для переписки: Садыхов О.Б., ovelsad@niuitmo.ru

10 июня 2026 г.

Аннотация

Цель. Построить интерпретируемую прогностическую модель рецидива диабетического кетоацидоза по клиническим данным пациента, реализовать сервис поддержки решений врача с расчетом в реальном времени и проверить две гипотезы.

Методы. Ретроспективная одноцентровая выборка 289 пациентов, из них 273 с известным исходом (рецидив 87, единичный эпизод 186, доля рецидивов 31.9%). Исход бинарный, стратифицированное разбиение на обучающую и тестовую части, подбор гиперпараметров во вложенной кросс-валидации, калибровка вероятностей и анализ кривых принятия решений. Разделяющую способность моделей сравнивали попарно критерием DeLong с поправкой Бенджамини-Хохберга.

Результаты. Подобраны восемь моделей-финалистов (логистическая регрессия, случайный лес, XGBoost, CatBoost на двух наборах признаков). Разделяющая способность по вложенной кросс-валидации 0.72–0.78 (лидер случайный лес на наборе без мультиколлинеарности 0.775), на отложенном тесте 0.72–0.80. Попарные критерии DeLong с поправкой Бенджамини-Хохберга не выявили значимых различий между финалистами ни на обучающей части, ни на тесте (0 значимых пар из 28 в обоих случаях), поэтому единую лучшую модель мы не выделяем. Гипотеза о превосходстве сложных моделей над логистической регрессией не подтвердилась: на обучающей части их преимущество незначимо (DeLong с поправкой $p = 0.09$), на тесте логистическая регрессия выше остальных. Стекинг, синтетическая балансировка и преобразования признаков прироста не дали. Предикторы с поправкой Бенджамини-Хохберга (q менее 0.05, всего 10): суточная доза инсулина, вид инсулинотерапии, длительность СД, ЛПВП, стадия и альбуминурия ХБП, ретинопатия, диабетическая нейропатия, прием алкоголя, HbA1c. Калибровку применяли выборочно, методом Платта там, где он снижает индекс Бриера. Порог подбирали под целевую чувствительность не ниже 0.75, на тесте это дает высокий NPV (0.75–0.92) при умеренном PPV. Гипотеза о связи приема алкоголя за сутки до эпизода с рецидивом подтвердилась (отношение шансов 2.27, $p = 0.008$).

Выводы. Модели применимы как инструмент скрининга риска. Для клинического внедрения нужны более крупная и полнее заполненная обучающая выборка и внешняя валидация на данных другого центра.

Ключевые слова: диабетический кетоацидоз, рецидив, прогностическая модель, машинное обучение, калибровка, поддержка принятия решений.

Keywords: diabetic ketoacidosis, recurrence, prognostic model, machine learning, calibration, clinical decision support.

1 Введение

Диабетический кетоацидоз - жизнеугрожающее осложнение сахарного диабета, для которого характерны неконтролируемая гипергликемия, метаболический ацидоз и повышенная концентрация кетоновых тел [1]. По данным анализа Desai с соавторами, за период с 2003 по 2014 год в США зарегистрировано 1 760 101 первичная госпитализация по поводу ДКА, а число выписок с основным диагнозом ДКА выросло со 118 808 в 2003 году до 188 965 в 2014 году, при внутрибольничной летальности 0.4% [2]. После купирования острого состояния пациенты сохраняют высокий риск рецидива, а повторные эпизоды протекают тяжелее и сопровождаются более высокой летальностью [3].

Повторные эпизоды ДКА редко объясняются одной причиной. В литературе к факторам риска повторных госпитализаций относят молодой возраст, психиатрические расстройства, инфекции, несоблюдение режима терапии, злоупотребление алкоголем и психоактивными веществами, а также социально-экономические обстоятельства [2, 3]. В повседневной практике врачу трудно заранее оценить, насколько высок риск повторного эпизода у конкретного пациента. Несмотря на десятилетия клинического опыта, оптимальные стратегии ведения ДКА остаются предметом дискуссий [4]. Набор факторов разнороден, а единого инструмента для оценки риска повторных эпизодов пока нет. Из-за этого врачи испытывают дефицит готовых решений для прогноза опасных эпизодов, такими решениями могут стать прогностические модели машинного обучения [5].

Методы машинного обучения и искусственного интеллекта здесь перспективны. Отдельные модели достигают ROC-AUC порядка 0.82–0.85 [5, 6], но их обобщающая способность ограничена: работы опираются на однородные популяции и отдельные источники данных с высокой долей пропусков, поэтому на других выборках метрики обычно не воспроизводятся, а применимость остается узкой [6]. Кроме того, ранее показано [7, 8], что многие модели работают как черный ящик: их выводы трудно интерпретировать и объяснить, что становится барьером для применения. Именно это питает недоверие врачей и сдерживает внедрение машинного обучения в медицине. В то же время современные работы по прогнозированию в диабетологии применяют методы объяснения предсказаний, прежде всего SHAP и LIME [9, 10]. При этом для прогнозирования рецидивов ДКА такие инструменты почти не применяются. Отсюда потребность в интерпретируемых прогностических инструментах для российской популяции.

В настоящей работе мы разрабатываем прогностическую модель повторных эпизодов ДКА по доступным клиническим показателям пациента на российской выборке. Акцент сделан на интерпретируемости предикторов, клинической применимости и подготовке прототипа сервиса поддержки принятия решений.

Мы проверяем две гипотезы. Первая клиническая. Прием алкоголя описан в литературе как фактор рецидивирующего течения ДКА: в обзоре Brandstaetter с соавторами прием алкоголя и психоактивных веществ связан с рецидивирующим кетоацидозом, а избыток алкоголя назван одним из частых провоцирующих факторов эпизода [11]. Связь подтверждают и работы по повторным госпитализациям: исследование случай-контроль Cooper с соавторами [12] и шкала риска ABCD Bradford с соавторами, где злоупотребление алкоголем и психоактивными веществами входит в число предикторов повторного поступления [13]. Мы проверяем, переносится ли эта связь на нашу выборку. Нулевая гипотеза: прием алкоголя за сутки до эпизода не связан с рецидивирующим течением, отношение шансов равно 1. Альтернативная гипотеза: связь есть, отношение шансов отличается от 1.

Вторая гипотеза методологическая. Систематический обзор Christodoulou с соавторами по 71 клинической прогностической задаче не выявил преимущества методов машинного обучения над логистической регрессией по разделяющей способности [14]. Мы проверяем, верно ли это для нашей задачи: дают ли более сложные модели (случайный лес, градиентный бустинг) более высокую разделяющую способность по ROC-AUC, чем логистическая регрессия. Сравнение проводим попарными критериями DeLong.

2 Схема этапов исследования

Схема на Рисунке 1 показывает путь работы. Основная линия ведет от данных к сервису, от нее ответвляются изученные альтернативы с короткими выводами. Зеленым выделены принятые решения. Сквозной вывод: ни градиентный бустинг, ни стекинг, ни синтетическая балансировка, ни преобразования признаков не подняли разделяющую способность выше потолка около 0.72–0.80 на этой выборке. Попарные критерии DeLong не выявили значимых различий между восемью финалистами, поэтому единую лучшую модель мы не выделяем, а в сервис выносим все восемь с выбором за врачом.

3 Методы

3.1 Дизайн и источник данных

Ретроспективное одноцентровое исследование на обезличенных данных. Учреждение не раскрывается по соглашению о конфиденциальности. В анализ включены пациенты, госпитализированные с диабетическим кетоацидозом в период с 2019 по 2025 год. Критерии включения - возраст 18 лет и старше и подтвержденный диагноз ДКА. Критерии исключения - утраченные или существенно неполные данные истории болезни, недостаточные для анализа. Это демонстрационная выборка из 289 пациентов, исход известен у 273. Расширенная база сейчас заполняется врачами.

3.2 Исход

Целевая переменная - рецидивирующее течение ДКА (0 - единичный эпизод, 1 - рецидив). Пациента относили к группе рецидива, если за время наблюдения у него зарегистрировано более одного эпизода ДКА. Это устанавливали по анамнезу на момент




Рис. 1. Схема этапов исследования и изученных вариантов. Зеленым выделены принятые решения.

поступления, когда пациент уже перенес несколько эпизодов, или по новому эпизоду, возникшему во время госпитализации. Единичным считали первое обращение или единственный эпизод за период наблюдения. Фиксированного окна наблюдения не было, исход определяли по совокупности анамнеза и периода госпитализации.

3.3 Предикторы

Использованы показатели, которые собирают при обычной госпитализации с ДКА, без дополнительных исследований специально для модели. Это демографические данные (возраст, пол), анамнез и терапия СД (тип, длительность, возраст манифестации, вид инсулинотерапии, суточная доза), лабораторные показатели при поступлении (газы крови, электролиты, креатинин, мочевины, глюкоза, HbA1c, липиды), осложнения (ХБП по стадиям и альбуминурии, ретинопатия, нейропатия) и фактор образа жизни (прием алкоголя). Все предикторы доступны на момент госпитализации. Рассмотрены два набора признаков: значимые по результатам сравнения групп (10) и набор без мультиколлинеарных показателей (25). Возраст связан с возрастом манифестации и длительностью СД почти линейным тождеством. Здесь r это коэффициент линейной корреляции Пирсона, мера силы линейной связи от -1 до 1, и r около 0.99 означает почти точную линейную зависимость, поэтому возраст манифестации исключали из набора без мультиколлинеарности как избыточный. Набор значимых признаков отобран по сравнению групп на полной когорте, до разделения на обучающую и тестовую части. Такой предварительный отбор на всей когорте может несколько завышать оценку именно для этого набора, что отмечено в ограничениях. Набор без мультиколлинеарности от исхода не зависит и такого смещения не несет.

3.4 Размер выборки

Формального расчета размера выборки не проводили, использована вся доступная демонстрационная когорта (273 пациента с известным исходом, доля рецидивов 31.9%, 87 событий рецидива). Для прогностических моделей ориентируются на число событий на предиктор (events per variable, EPV) - сколько наблюдений редкого класса приходится на один признак модели. Симуляционная работа Peduzzi с соавторами показала, что при числе событий на предиктор меньше 10 оценки коэффициентов логистической регрессии становятся неустойчивыми, отсюда распространенный порог не менее 10 событий на признак [15]. У нас 87 событий, поэтому EPV равен 8.7 для набора из 10 признаков (87 на 10) и 3.5 для набора из 25 признаков (87 на 25), то есть ниже порога, особенно для расширенного набора. Это ограничивает число признаков, которое можно надежно оценить, и повышает риск переобучения. Поэтому мы ограничили размерность, применяли регуляризацию (L2-штраф на коэффициенты у логистической регрессии, ограничение глубины и минимального размера листа у деревьев, штрафы l2_leaf_reg и lambda у бустингов) и взвешивание классов (class_weight balanced, когда вес класса обратно пропорционален его частоте, поэтому редкий класс рецидива получает больший вес в функции потерь). Обобщение оценивали вложенной кросс-валидацией и приводим 95% доверительные интервалы метрик, которые при такой выборке получаются широкими (около 0.13 по ширине). Отсутствие переобучения подтверждали тремя независимыми способами: согласием оценок на вложенной кросс-валидации и отложенном тесте, ООВ-оценкой случайного

леса (бэггинг деревьев) и бутстрэп-доверительными интервалами метрик.

3.5 Пропущенные данные

Доля пропусков по показателям менялась от единиц процентов до 58% (HbA1c, натрий, калий, лактат). Механизм оценен преимущественно как MAR с панельной структурой, когда лабораторные показатели пропадают группами. Сравнили стратегии импутации - медиану и моду, KNN, MICE и ручную клиническую импутацию по правилам (арифметика возраста, формула Фридвальда для ЛПНП, степень тяжести из pH, групповые медианы острых показателей по тяжести, креатинин по полу). Импутер обучали только на обучающей части внутри фолдов. На тесте пропуски заполняются по ближайшим соседям из обучающей части, тестовые строки не используют ни исход, ни друг друга. Рабочей выбрана KNN-импутация с пятью соседями. Она превосходила остальные стратегии по качеству модели и при этом не искажала форму распределений: по критерию Колмогорова-Смирнова распределения до и после импутации значимо не различались, а пиковые значения не стягивались к медиане, как при заполнении медианой. Число соседей сравнивали отдельно (k от 3 до 11) по out-of-fold ROC-AUC на обучающей части, оптимальным оказалось $k = 5$ (ROC-AUC лидера 0.772 против 0.72–0.76 при остальных значениях k).

3.6 Статистический анализ

Нормальность проверяли критерием Шапиро-Уилка при n менее 50 и критерием Колмогорова-Смирнова в варианте Лиллиефорса (с оценкой параметров по выборке) при n не менее 50. Количественные показатели при нормальном распределении описывали средним и стандартным отклонением с 95% доверительным интервалом, при отклонении от нормального - медианой и квантилями. Группы сравнивали t -критерием Стьюдента, U -критерием Манна-Уитни или W -критерием Бруннера-Мюнцеля в зависимости от нормальности и равенства дисперсий (критерий Левена). Доли сравнивали критерием хи-квадрат Пирсона или точным критерием Фишера, 95% доверительный интервал для долей считали методом Клоппера-Пирсона, размер эффекта - отношением шансов с 95% доверительным интервалом. При множественных сравнениях применяли поправку Бенджамини-Хохберга. Площади под ROC двух моделей на одних и тех же пациентах сравнивали критерием DeLong для связанных ROC-кривых, дополнительно парным бутстрэпом разницы AUC.

3.7 Разработка модели

Выборку один раз стратифицированно разделили на обучающую (218) и тестовую (55) части. Всю предобработку - импутацию, масштабирование, кодирование категориальных, балансировку - выполняли внутри пайплайна и обучали только на обучающих фолдах. На этапе выбора стратегий предобработки сравнили семейства моделей (логистическая регрессия, случайный лес, LightGBM, CatBoost, XGBoost, метод опорных векторов, метод k ближайших соседей) по осям импутации, балансировки, кодирования категориальных и преобразования количественных признаков. По итогам в дальнейшую работу взяли четыре семейства, логистическую регрессию, случайный лес, XGBoost и CatBoost, на двух наборах признаков, всего восемь моделей-финалистов. CatBoost обрабатывает категориальные признаки на-

тивно, упорядоченными целевыми статистиками, без one-hot кодирования. Дисбаланс классов учитывали взвешиванием классов, синтетические методы (SMOTE, SMOTENC, BorderlineSMOTE, ADASYN) сравнивали отдельно и прироста они не дали. Гиперпараметры подбирали байесовским поиском Optuna (TRE-сэмплер с ранней отбраковкой неперспективных наборов) во вложенной кросс-валидации. Качество всей процедуры оценивали по внешней пятифолдовой кросс-валидации, а внутри каждого обучающего фолда Optuna подбирала гиперпараметры по отдельной трехфолдовой кросс-валидации. Внутреннее разбиение нужно, чтобы сравнивать наборы гиперпараметров на данных, которые модель при обучении не видела. Иначе подбор и оценка шли бы по одним и тем же наблюдениям, и качество оказалось бы завышенным. Финальные гиперпараметры для развертывания получали отдельным запуском Optuna на всей обучающей части (пятифолдовая кросс-валидация, 100 испытанных наборов гиперпараметров).

3.8 Оценка качества и клиническая польза

Качество оценивали по ROC-AUC, PR-AUC, чувствительности, специфичности и индексу Бриера. Калибровку проверяли по out-of-fold надежностным кривым и индексу Бриера, сравнивая сырые вероятности с методами Платта и изотонической регрессии. Калибровку применяли выборочно, только там, где она снижала индекс Бриера не менее чем на 0.005, иначе оставляли сырые вероятности как более устойчивые на малой выборке. Клиническую пользу оценивали анализом кривых принятия решений. Порог классификации подбирали для каждой модели отдельно на out-of-fold вероятностях обучающей части: брали порог с целевой чувствительностью не ниже 0.75 и наибольшей при этом специфичностью. Для сравнения приводили индекс Юдена $J = \text{чувствительность} + \text{специфичность} - 1$. Его максимум это точка наилучшего совместного баланса чувствительности и специфичности, и при фиксированной чувствительности максимум индекса Юдена совпадает с максимумом специфичности, поэтому наш способ выбора порога согласуется с ним. Найденный порог фиксировали и проверяли на тесте. Доверительные интервалы метрик получали бутстрэпом (2000 повторов), отложенный тест использовали один раз.

3.9 Интерпретация

Вклад признаков оценивали методом SHAP для всех финалистов: линейный SHAP (LinearExplainer) для логистической регрессии, TreeExplainer для случайного леса и XGBoost, встроенные ShapValues для CatBoost на нативной матрице с категориями. Вклады one-hot кодированных категорий суммировали обратно к исходному признаку. У CatBoost ранжирование по SHAP сопоставляли со встроенной важностью (PredictionValuesChange) коэффициентом ранговой корреляции Спирмена. Спирмен сравнивает не сами значения важности, а порядок признаков по важности, поэтому подходит, когда две меры выражены в разных единицах и связь между ними не обязана быть линейной. Результаты сверяли с классической статистикой и клинической логикой.

3.10 Программное обеспечение и отчетность

Анализ выполнен на Python 3.11 с фиксированными версиями библиотек, код открыт. Отчетность построена по рекомендациям TRIPOD+AI.

3.11 Этическое одобрение

Работа выполнена на обезличенных ретроспективных данных и не требует одобрения этического комитета.

4 Результаты

4.1 Характеристика участников

Поток пациентов от исходной когорты до обучающей и тестовой частей показан на Рисунке 2.

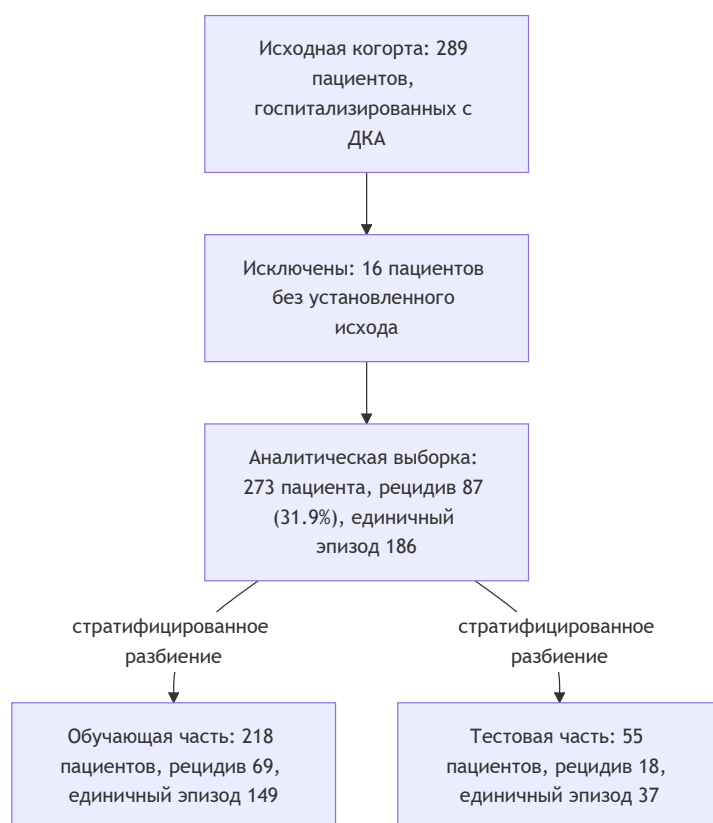


Рис. 2. Поток пациентов: формирование аналитической выборки и разбиение.

Группа без рецидива 186 пациентов, группа рецидива 87. В Таблице 1 собраны показатели со значимым различием между группами после поправки Бенджамини-Хохберга (q менее 0.05), всего 10. Полная характеристика когорты приведена в дополнительных материалах.

Для количественных показателей даны медиана и квантили или M (SD) в зависимости от нормальности. Для категориальных приведена доля характерного уровня от полной группы (остаток до 100% - пропуски), отношение шансов рассчитано только для бинарных показателей. По виду инсулинотерапии главное различие не в доле помповой терапии, а в доле пациентов без инсулинотерапии: у группы без рецидива это 28.0% против 1.1% при рецидиве, что отражает структурный сигнал дебюта (первый эпизод не может быть рецидивом).

Таблица 1. Предикторы со значимым различием между группами (поправка Бенджамини-Хохберга).

Показатель	Без рецидива (n=186)	Рецидив (n=87)	p	q (BH)	ОШ (95% ДИ)
Суточная доза инсулина, ед., Me [Q1; Q3]	34 [0; 45]	44 [35; 54]	<0.0001	<0.0001	-
Вид инсулинотерапии, доля без инсулинотерапии (дебют)	28.0%	1.1%	<0.0001	<0.0001	-
ЛПВП, ммоль/л, M (SD)	1.09 (0.35)	1.34 (0.47)	0.0007	0.0065	-
Длительность СД, лет, Me [Q1; Q3]	6 [0; 12.5]	9 [4; 15]	0.0021	0.0139	-
НЬА1с, %, Me [Q1; Q3]	12.56 [10.28; 13.64]	10.90 [8.91; 12.66]	0.0058	0.0196	-
Ретинопатия, доля без ретинопатии	55.9%	44.8%	0.0049	0.0196	-
ХБП, стадия С, доля без поражения (C0)	36.0%	18.4%	0.0060	0.0196	-
ХБП, альбуминурия А, доля без альбуминурии (A0)	26.3%	17.2%	0.0057	0.0196	-
Алкоголь за сутки до ДКА, доля	15.1%	28.7%	0.0081	0.0234	2.27 [1.23; 4.20]
Диабетическая нейропатия (осмотр невролога), доля	45.7%	66.7%	0.0108	0.0281	2.05 [1.17; 3.57]

4.2 Гипотеза о приеме алкоголя

Гипотезу о связи приема алкоголя за сутки до эпизода с рецидивом проверяли отдельно. Значение признака известно у 269 пациентов из 273. Среди пациентов с рецидивом алкоголь за сутки до эпизода принимали 29.1% (25 из 86), в группе единичного эпизода 15.3% (28 из 183). Минимальная ожидаемая частота в четырехпольной таблице 16.9, она больше 10, поэтому по протоколу применен критерий хи-квадрат Пирсона: статистика критерия 7.01, $p = 0.008$. Нулевую гипотезу об отсутствии связи отклоняем. Отношение шансов рецидива при приеме алкоголя 2.27 (95% ДИ 1.23–4.20): прием алкоголя накануне повышает шансы рецидивирующего течения примерно вдвое. После поправки Бенджамини-Хохберга на множественные сравнения в Таблице 1 связь сохраняет значимость ($q = 0.023$). Направление и сила эффекта согласуются с данными литературы по факторам рецидива ДКА [11, 12, 13].

4.3 Разработка и качество модели

Гиперпараметры подобраны Optuna во вложенной кросс-валидации. Вложенная ROC-AUC - честная оценка процедуры подбора, по финалистам на двух наборах признаков она приведена в Таблице 2.

Таблица 2. Разделяющая способность финалистов по вложенной кросс-валидации.

Модель	Набор	Вложенная ROC-AUC	SD
Случайный лес	без мультиколл. (25)	0.775	0.019
XGBoost	без мультиколл. (25)	0.748	0.038
CatBoost	без мультиколл. (25)	0.735	0.050
Логистическая регрессия	без мультиколл. (25)	0.713	0.029
Случайный лес	значимые (10)	0.719	0.069
XGBoost	значимые (10)	0.710	0.106
CatBoost	значимые (10)	0.706	0.075
Логистическая регрессия	значимые (10)	0.680	0.082

Лидер - случайный лес на наборе без мультиколлинеарности (0.775, самый узкий разброс по фолдам), за ним XGBoost и CatBoost на том же наборе. Набор из 25 признаков у всех деревьев обходит набор из 10. LightGBM входил в шортлист подбора, но в финалисты не включен: его внутренняя оценка заметно расходилась с вложенной, что указывает на переобучение под фолды. Подбор гиперпараметров не поднял качество над разумными значениями по умолчанию из этапа выбора стратегий, где лучшая конфигурация давала около 0.78 на одиночной кросс-валидации: основной рычаг - выбор модели и набора признаков, а не тонкая настройка, что ожидаемо при выборке в 218 пациентов. Единую основную модель не выделяем: попарные сравнения финалистов (ниже) не обнаружили значимых различий, поэтому в сервис и интерпретацию несем все восемь, оставляя выбор за врачом.

4.4 Устойчивость оценок и отсутствие переобучения

Для каждого финалиста получены ROC-AUC и PR-AUC по out-of-fold с 95% доверительным интервалом по бутстрэпу (2000 повторов). Лучшая оценка у случайного леса

на наборе без мультиколлинеарности: ROC-AUC 0.772 [0.710; 0.833], следом CatBoost 0.764 и XGBoost 0.761, на наборе значимых признаков все финалисты около 0.73. Доверительные интервалы широкие (около 0.13 по ширине) и сильно перекрываются. Само по себе перекрытие интервалов не доказывает равенства моделей, поэтому различия проверяли формально, попарным критерием DeLong (см. раздел об оценке на тесте). PR-AUC держится в диапазоне 0.50–0.55 при базовой линии случайного классификатора около 0.32, то есть модели несут сигнал и для несбалансированной задачи. ООВ-оценка случайного леса согласуется с out-of-fold (0.721 против 0.732 на значимом наборе и 0.749 против 0.772 на наборе без мультиколлинеарности) - две независимые оценки совпадают, признаков переобучения нет. Качество на отложенном тесте (диапазон 0.72–0.80) согласуется с вложенной кросс-валидацией, что подтверждает вывод.

4.5 Оценка на отложенном тесте

Тест 55 пациентов, тронут один раз. Разделяющая способность всех восьми финалистов приведена в Таблице 3.

Таблица 3. Разделяющая способность финалистов на отложенном тесте.

Модель	Набор	ROC-AUC (95% ДИ)
Логистическая регрессия	без мультиколл. (25)	0.802 [0.672; 0.912]
XGBoost	значимые (10)	0.769 [0.632; 0.889]
XGBoost	без мультиколл. (25)	0.769 [0.630; 0.888]
CatBoost	значимые (10)	0.739 [0.587; 0.864]
CatBoost	без мультиколл. (25)	0.739 [0.587; 0.868]
Случайный лес	значимые (10)	0.734 [0.579; 0.864]
Логистическая регрессия	значимые (10)	0.731 [0.582; 0.861]
Случайный лес	без мультиколл. (25)	0.724 [0.576; 0.851]

Все оценки лежат в коридоре 0.72–0.80, доверительные интервалы широкие (около плюс-минус 0.13) и перекрываются. Ранжирование на тесте разошлось с вложенной кросс-валидацией: лидер CV, случайный лес на наборе без мультиколлинеарности, на тесте оказался внизу коридора, а логистическая регрессия на том же наборе - вверху.

Чтобы не судить о различиях по перекрытию интервалов, мы сравнили все восемь финалистов попарно критерием DeLong для связанных ROC-кривых с поправкой Бенджамини-Хохберга на 28 сравнений. Ни одна пара не показала значимого различия: ни на out-of-fold обучающей части (0 значимых пар из 28), ни на отложенном тесте (0 из 28). Это не доказывает равенства моделей, при выборке в 55 человек мощность теста мала, но и не дает оснований выделить какую-то модель как лучшую. Поэтому в сервис мы выносим все восемь финалистов.

4.6 Гипотеза о сложности модели

Гипотезу о превосходстве сложных моделей проверяли не на одной выбранной паре, а по всем трем сложным семействам против логистической регрессии на наборе

без мультиколлинеарности, парным критерием DeLong с поправкой Бенджамини-Хохберга, отдельно на out-of-fold обучающей части и на тесте (Таблица 4). На обучающей части все три модели номинально выше логрега (разница 0.04–0.05), но после поправки различие незначимо ни у одной ($p = 0.09$). На отложенном тесте знак разницы обратный: логистическая регрессия выше всех трех сложных моделей (на 0.03–0.08), и здесь различия тоже незначимы. Гипотезу о превосходстве сложных моделей над логистической регрессией отклоняем: устойчивого преимущества по разделяющей способности на этой выборке нет. Это согласуется с систематическим обзором Christodoulou с соавторами, где машинное обучение не превзошло логистическую регрессию [14].

Таблица 4. Сложные модели против логистической регрессии (набор без мультиколлинеарности), критерий DeLong.

Выборка	Сложная модель	AUC сложной	AUC логрега	Разница	DeLong p (BH)
OOF	случайный лес	0.772	0.719	+0.052	0.09
OOF	XGBoost	0.761	0.719	+0.041	0.09
OOF	CatBoost	0.764	0.719	+0.045	0.09
тест	случайный лес	0.724	0.802	−0.078	0.50
тест	XGBoost	0.769	0.802	−0.033	0.55
тест	CatBoost	0.739	0.802	−0.063	0.50

4.7 Калибровка и выбор порога

Калибровку оценивали по out-of-fold на обучающей части. На наборе без мультиколлинеарности сырые вероятности уже хорошо откалиброваны (индекс Бриера 0.178–0.189), Платт и изотоническая их не улучшают. Заметный выигрыш от Платта есть только у логистической регрессии и случайного леса на значимом наборе (индекс Бриера 0.199 против 0.189 и 0.203 против 0.183). Поэтому калибровку применяли выборочно: Платт у этих двух моделей, сырые вероятности у остальных шести. Анализ кривых принятия решений показывает чистую пользу выше стратегий лечить всех и не лечить никого в клинически разумном диапазоне порогов.

Порог подбирали для каждого финалиста на out-of-fold вероятностях обучающей части по целевой чувствительности не ниже 0.75 и фиксировали. На обучающей части чувствительность держалась у цели (0.75–0.78) при специфичности 0.49–0.68 в зависимости от модели и набора. На тесте порог переносился с разбросом, ожидаемым при 18 событиях: чувствительность 0.50–0.89, специфичность 0.49–0.73. Лучшая рабочая точка на тесте у XGBoost - чувствительность 0.72 при специфичности 0.73. Высокий NPV (0.75–0.92) при умеренном PPV (0.41–0.73) отражает распространенность исхода и соответствует задаче скрининга: модель надежнее отсеивает низкий риск, чем подтверждает высокий.

4.8 Преобразования признаков

Влияние преобразований количественных признаков (логарифм и Йео-Джонсон по схеме скошенности против только стандартизации) проверено на этапе выбора стратегий для всех моделей и обоих наборов. Значимого выигрыша нет ни у одной модели:

сдвиги ROC-AUC не превышают 0.02 при ширине доверительного интервала около 0.13. Деревья ожидаемо инвариантны к монотонным преобразованиям отдельных признаков. В пайплайне оставлена стандартизация без дополнительного преобразования.

4.9 Стекинг

Мы оценили стекинг как способ объединить модели. Базовыми были восемь финалистов, мета-моделью - логистическая регрессия над их out-of-fold предсказаниями. Перебрали все комбинации от двух базовых моделей и сравнили их по out-of-fold ROC-AUC. Лучшая комбинация дала 0.7705, что близко к лучшей одиночной модели (случайный лес на наборе без мультиколлинеарности, 0.772) и не превышает ее. Двухмодельный стек был не хуже комбинаций из четырех-пяти, то есть добавление базовых моделей качество не повышало, что объяснимо общим сигналом финалистов. На нашей выборке заметного прироста стекинг не дал, а интерпретируемость при этом снижается: вклад признаков приходится проследживать через мета-модель. Поэтому в сервис мы вынесли одиночные модели как более простые и прозрачные. На большей выборке выигрыш от стекинга не исключен, это направление для дальнейшей работы.

4.10 Синтетическая балансировка

На лучшей не-CatBoost модели (случайный лес на наборе без мультиколлинеарности) сравнили синтетические методы SMOTENC, BorderlineSMOTE, ADASYN и обычный SMOTE с двумя несинтетическими вариантами: взвешиванием классов и отсутствием балансировки, по пяти повторам. Оверсэмплинг выполняли только внутри фолдов, оценивали на реальной валидации. Синтетика прироста не дала: ROC-AUC у синтетических методов 0.715–0.725, тогда как без балансировки 0.729, а при взвешивании классов 0.737. То есть лучший результат дал несинтетический прием - взвешивание классов, которое не создает новых строк, а лишь повышает вес редкого класса в функции потерь. PR-AUC у синтетики даже чуть ниже, а индекс Бриера растет с 0.187 до 0.193–0.200, то есть калибровка ухудшается. У синтетики при пороге 0.5 растет чувствительность, но это не улучшение разделяющей способности, а лишь смещение вероятностей, при котором тот же порог 0.5 относит к положительным больше пациентов. Того же эффекта чище добиться прямым снижением порога, что мы и делаем. Синтетическую балансировку в пайплайн не включили.

4.11 Значимость признаков

SHAP рассчитан для всех восьми финалистов (логистическая регрессия, случайный лес, XGBoost, CatBoost на двух наборах, рисунки приведены в дополнительных материалах). Размер топа подобран под набор: топ-5 для значимого набора из 10 признаков, где топ-10 включил бы все, и топ-10 для набора без мультиколлинеарности из 25 признаков. На значимом наборе в топ-5 у всех четырех семейств одновременно стоят вид инсулинотерапии и стадия ХБП-С, на наборе из 25 признаков общими в топ-10 оказались вид инсулинотерапии, суточная доза инсулина, HbA1c, ЛПВП и глюкоза при поступлении. Сквозное ядро через все модели - вид инсулинотерапии и суточная доза инсулина. Логистическая регрессия дополнительно поднимает электролиты (натрий, калий), деревья и CatBoost - длительность СД, общий холестерин и

тип СД, что отражает разную природу моделей. У CatBoost ранжирование по SHAP согласуется со встроенной важностью (PredictionValuesChange): коэффициент Спирмена 0.79 на значимом наборе при пересечении топ-5 четыре из пяти и 0.90 на наборе без мультиколлинеарности при пересечении топ-10 девять из десяти. Набор важных признаков совпадает со значимыми по Таблице 1, направления влияния клинически логичны.

5 Обсуждение

Мы построили и проверили на отложенном тесте модели прогноза рецидивирующего течения ДКА по клиническим показателям. Разделяющая способность держится около 0.72–0.78 на вложенной кросс-валидации и в коридоре 0.72–0.80 на отложенном тесте. Внутри этого потолка выбор стратегии предобработки имел значение: KNN-импутация с пятью соседями оказалась лучшей среди стратегий заполнения пропусков, а взвешивание классов лучшим среди приемов балансировки. Но поднять разделяющую способность выше потолка не удалось ни градиентному бустингу, ни стекингу, ни синтетической балансировке, ни преобразованиям количественных признаков. Попарные критерии DeLong с поправкой Бенджамини-Хохберга не выявили значимых различий между восемью финалистами ни на обучающей части, ни на тесте (0 значимых пар из 28 в обоих случаях). При выборке такого объема это не доказывает равенства моделей, мощность теста мала, но и не дает оснований выделить одну как лучшую, поэтому в сервис мы выносим все восемь, оставляя выбор за врачом.

Методологическая гипотеза о превосходстве сложных моделей не подтвердилась. На вложенной кросс-валидации случайный лес, XGBoost и CatBoost номинально выше логистической регрессии (0.74–0.78 против 0.71 на наборе без мультиколлинеарности), но после поправки различие незначимо, а на отложенном тесте порядок обратный: выше всех оказалась логистическая регрессия (0.802). Это согласуется с систематическим обзором Christodoulou с соавторами, где машинное обучение не превзошло логистическую регрессию [14]. Логистическая регрессия ценна как самая простая и интерпретируемая модель с естественной калибровкой. Случайный лес и XGBoost дают то же качество за счет нелинейных взаимодействий. CatBoost удобен тем, что обрабатывает категориальные признаки без one-hot кодирования. Все модели допускают регулировку порога под клиническую задачу.

Состав значимых предикторов устойчив. Вид инсулинотерапии, суточная доза инсулина, стадия и альбуминурия ХБП и длительность СД попадают и в значимые по Таблице 1, и в общее ядро SHAP сразу у всех моделей. Совпадение результатов классической статистики и метода объяснения предсказаний, полученное двумя независимыми путями, усиливает доверие к набору факторов.

Наши оценки скромнее опубликованных. Li с соавторами на когорте взрослых с СД 1 типа по данным электронных историй болезни получили ROC-AUC около 0.82 [6], причем различия между методами машинного обучения и логистической регрессией у них были минимальны, что согласуется с нашим результатом. Близкий уровень (ROC-AUC до 0.85) показывает модель Williams с соавторами на когорте детей с СД 1 типа [5]. Разрыв с нашими оценками объясняется размером и характером данных: у нас демонстрационная одноцентровая выборка из 273 пациентов против десятков тысяч наблюдений в этих работах, а также другим определением исхода. Мы прогнозировали рецидивирующее течение по совокупности анамнеза и периода гос-

питализации без фиксированного окна, тогда как часть литературы предсказывает госпитализацию или повторную госпитализацию в заданном временном окне. Состав факторов риска согласуется с литературой. Обзор Mohler с соавторами связывает повторную госпитализацию при ДКА с социально-экономическими факторами, такими как доступ к помощи, приверженность терапии и уровень дохода [3], а работы по клиническим факторам рецидива Brandstaetter и Cooper с соавторами называют длительность и характер терапии диабета, сопутствующие осложнения и злоупотребление алкоголем [11, 12]. Эти группы факторов проявились и в нашей выборке. Гипотеза о связи приема алкоголя за сутки до эпизода с рецидивирующим течением подтвердилась (отношение шансов 2.27, $p = 0.008$), что переносит известный из литературы фактор на нашу популяцию.

Сильные стороны работы методологические. Разбиение на обучающую и тестовую части сделано один раз и до любой предобработки, а импутацию, масштабирование и отбор обучают внутри фолдов кросс-валидации. Это дает несмещенную, не оптимистичную оценку того, как модель поведет себя на новых пациентах, что особенно важно при малой выборке, где утечка легко завышает метрики. Отсутствие переобучения подтверждено тремя независимыми способами: согласием вложенной кросс-валидации и отложенного теста, совпадением ООВ-оценки леса с out-of-fold оценкой и широкими, но согласованными бутстрэп-интервалами. Помимо разделяющей способности мы оценили калибровку и клиническую пользу через анализ кривых принятия решений, а интерпретацию провели методом SHAP по всем финалистам и сверили со статистикой и встроенной важностью CatBoost.

Ограничения существенны. Выборка одноцентровая, малая и демонстрационная, поэтому доверительные интервалы метрик широкие, а попарные различия между финалистами по критерию DeLong незначимы. Внешней валидации на независимой популяции нет. Доля пропусков в части лабораторных показателей высокая (до 58% по HbA1c, натрию, калию и лактату), и хотя KNN-импутация не исказила распределения, неопределенность сохраняется. Определение исхода без фиксированного окна наблюдения смешивает анамнестический рецидив и эпизод, возникший во время госпитализации, что может вносить неоднородность. Набор значимых признаков отобран по сравнению групп на полной когорте, до разделения на обучающую и тестовую части, поэтому оценка именно для этого набора может быть несколько завышена. Набор без мультиколлинеарности от исхода не зависит и такого смещения не несет, и на нем получены лучшие честные оценки. Дизайн ретроспективный, со свойственными ему ограничениями по полноте и качеству данных.

Клиническое значение работы прикладное. На основе модели собран прототип сервиса поддержки решений, который по показателям пациента выдает вероятность рецидива, вклад признаков и регулируемый порог, и дает выбор из восьми финалистов на двух наборах признаков. Рабочий режим - скрининг: порог подобран под целевую чувствительность не ниже 0.75, при которой модели дают высокий NPV (0.75–0.92) при умеренном PPV (0.41–0.73), то есть надежнее отсеивают пациентов низкого риска, чем подтверждают высокий. Сервис задуман как вспомогательный инструмент врача, а не как средство постановки диагноза.

6 Выводы

По рутинным клиническим показателям рецидивирующее течение ДКА прогнозируется с умеренной разделяющей способностью около 0.72–0.78 по вложенной кросс-

валидации. Сложные модели, стекинг и синтетическая балансировка преимущества над более простыми не дали, а попарные критерии DeLong не выявили значимых различий между восемью финалистами. Поэтому единую модель мы не выделяем, в сервис вынесены все восемь с выбором за врачом, при этом логистическая регрессия ценна как интерпретируемая и естественно калиброванная. Устойчивое ядро предикторов (вид инсулинотерапии, суточная доза инсулина, ХБП, длительность СД) согласуется между классической статистикой и SHAP. Модели применимы как инструмент скрининга риска с высоким NPV. Для клинического внедрения нужны более крупная и полнее заполненная обучающая выборка и внешняя валидация на данных другого центра.

Дополнительные сведения

- Доступность данных: данные пациентов закрыты, доступ по обоснованному запросу в рамках этических ограничений.
- Доступность кода: открытый репозиторий, фиксированные версии, инструкции по воспроизведению.
- Дополнительные материалы: полные таблицы результатов (характеристика когорты, подбор гиперпараметров, калибровка, пороги, стекинг, синтетическая балансировка) и рисунки SHAP доступны в репозитории и предоставляются по запросу.
- Этическое одобрение: работа выполнена на обезличенных ретроспективных данных и не требует одобрения этического комитета.
- Финансирование: исследование выполнено без внешнего финансирования.
- Конфликт интересов: авторы заявляют об отсутствии конфликта интересов.
- Вклад авторов: Садыхов О.Б. - концепция исследования, подготовка и анализ данных, разработка и валидация моделей, реализация сервиса, написание рукописи. Леоненко В.Н. - научное руководство, концепция исследования, критический пересмотр и редактирование рукописи, утверждение окончательного варианта.
- Благодарности: авторы благодарят научного руководителя и врачей, предоставивших клинические данные.

Список литературы

- [1] Benoit SR, Zhang Y, Geiss LS, Gregg EW, Albright A. Trends in diabetic ketoacidosis hospitalizations and in-hospital mortality - United States, 2000-2014. MMWR Morb Mortal Wkly Rep. 2018;67(12):362-365. <https://pmc.ncbi.nlm.nih.gov/articles/PMC5877353/>
- [2] Desai D, Mehta D, Mathias P, Menon G, Schubart UK. Health care utilization and burden of diabetic ketoacidosis in the U.S. over the past decade: a nationwide analysis. Diabetes Care. 2018;41(8):1631-1638. <https://pubmed.ncbi.nlm.nih.gov/29773640/>

- [3] Mohler R, Lotharius K, Moothedan E, Goguen J, Bandi R, Beaton R, Knecht M, Mejia MC, Khoury M, Sacca L. Factors contributing to diabetic ketoacidosis readmission in hospital settings in the United States: a scoping review. *J Diabetes Complications*. 2024;38(10):108835. <https://pubmed.ncbi.nlm.nih.gov/39137675/>
- [4] Omar Salem Kanzwl S, Alhajri AHM, Mohammed YJA, et al. A comparative effectiveness of intravenous fluids and insulin regimens in the acute management of diabetic ketoacidosis and hypoglycemia: a systematic review. *Cureus*. 2025;17(10):e94902. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12624376/>
- [5] Williams DD, Ferro D, Mullaney C, Skrabonja L, Barnes MS, Patton SR, Locke B, Tallon EM, Vandervelden CA, Schweisberger C, Mehta S, McDonough R, Lind M, D'Avolio L, Clements MA. An all-data-on-hand deep learning model to predict hospitalization for diabetic ketoacidosis in youth with type 1 diabetes: development and validation study. *JMIR Diabetes*. 2023;8:e47592. <https://diabetes.jmir.org/2023/1/e47592>
- [6] Li L, Lee CC, Zhou FL, Molony C, Doder Z, Zalmover E, Sharma K, Juhaeri J, Wu C. Performance assessment of different machine learning approaches in predicting diabetic ketoacidosis in adults with type 1 diabetes using electronic health records data. *Pharmacoepidemiol Drug Saf*. 2021;30(5):610-618. <https://pmc.ncbi.nlm.nih.gov/articles/PMC8049019/>
- [7] Rudin C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nat Mach Intell*. 2019;1(5):206-215. <https://www.nature.com/articles/s42256-019-0048-x>
- [8] Stiglic G, Kocbek P, Fijacko N, Zitnik M, Verbert K, Cilar L. Interpretability of machine learning based prediction models in healthcare. *WIREs Data Min Knowl Discov*. 2020;10(5):e1379. <https://arxiv.org/abs/2002.08596>
- [9] Ahmed S, Kaiser MS, Hossain MS, Andersson K. A comparative analysis of LIME and SHAP interpreters with explainable ML-based diabetes predictions. *IEEE Access*. 2024;12. <https://ieeexplore.ieee.org/document/10583856/>
- [10] Emi-Johnson OG, Nkrumah KJ. Predicting 30-day hospital readmission in patients with diabetes using machine learning on electronic health record data. *Cureus*. 2025;17(4):e82437. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12085305/>
- [11] Brandstaetter E, Bartal C, Sagy I, Jotkowitz A, Barski L. Recurrent diabetic ketoacidosis. *Arch Endocrinol Metab*. 2019;63(5):531-535. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10522260/>
- [12] Cooper H, Tekiteki A, Khanolkar M, Braatvedt G. Risk factors for recurrent admissions with diabetic ketoacidosis: a case-control observational study. *Diabet Med*. 2016;33(4):523-528. <https://pubmed.ncbi.nlm.nih.gov/26489986/>
- [13] Bradford AL, Crider CC, Xu X, Naqvi SH. Predictors of recurrent hospital admission for patients presenting with diabetic ketoacidosis and hyperglycemic hyperosmolar state. *J Clin Med Res*. 2017;9(1):35-39. <https://pubmed.ncbi.nlm.nih.gov/27924173/>

- [14] Christodoulou E, Ma J, Collins GS, Steyerberg EW, Verbakel JY, Van Calster B. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *J Clin Epidemiol*. 2019;110:12-22. <https://pubmed.ncbi.nlm.nih.gov/30763612/>
- [15] Peduzzi P, Concato J, Kemper E, Holford TR, Feinstein AR. A simulation study of the number of events per variable in logistic regression analysis. *J Clin Epidemiol*. 1996;49(12):1373-1379. <https://pubmed.ncbi.nlm.nih.gov/8970487/>